

Università degli Studi di Parma
Dipartimento di Ingegneria e Architettura
Corso di Laurea in Ingegneria Informatica
Curriculum: Intelligenza Artificiale

Deep Learning e Modelli Generativi

Docente: Prof. Andrea Prati

Image_Captioning_CNN_LSTM

Studente: Giuseppe Dimonte
Matricola: 367431
Email: giuseppe.dimonte@studenti.unipr.it

Indice

Sommario

Questo report presenta l'implementazione e la valutazione di un sistema di image captioning basato su architettura CNN-LSTM addestrato sul dataset Flickr8k. Il progetto copre l'intera pipeline richiesta dall'assegnamento: preprocessing delle caption, costruzione del vocabolario, preparazione dei file di training e validation, addestramento supervisionato, valutazione con metriche BLEU e analisi qualitativa dei risultati. È stata inoltre condotta una campagna sperimentale controllata su quattro configurazioni: baseline, rimozione dello scheduled sampling, rimozione del label smoothing e fine-tuning della CNN. Il miglior risultato è stato ottenuto dalla configurazione con fine-tuning, che ha raggiunto un BLEU-4 pari a 0.0649, superiore al valore di baseline pari a 0.0472.

1 Introduzione

L'image captioning è un problema multimodale in cui un sistema deve ricevere un'immagine in input e generare una descrizione testuale coerente con il contenuto visivo. Il compito combina due aspetti distinti: comprensione visiva e generazione linguistica. Per questo motivo può essere formulato naturalmente come problema image-to-sequence.

L'obiettivo di questo progetto è stato implementare una pipeline completa di image captioning basata su CNN-LSTM, in accordo con i requisiti dell'assegnamento del corso. Oltre alla realizzazione del modello, il lavoro ha richiesto una particolare attenzione alla riproducibilità dell'intero flusso, dalla preparazione dei dati alla raccolta sistematica dei risultati sperimentali.

2 Traccia dell'assegnamento

La traccia richiedeva:

- l'utilizzo del dataset Flickr8k;
- l'implementazione di una architettura CNN-LSTM;
- la pulizia del testo delle caption;
- la costruzione di un dizionario/vocabolario da salvare su file;
- l'accoppiamento tra feature visuali e sequenze testuali durante il training;
- la generazione delle caption in fase di test a partire dall'output del decoder.

Il progetto finale soddisfa questi requisiti attraverso una pipeline modulare e riproducibile.

3 Dataset e preprocessing

3.1 Dataset Flickr8k

Flickr8k è un dataset di image captioning in cui ogni immagine è associata a cinque caption di riferimento. Nel progetto sono stati prodotti artefatti preprocessati per rendere il workflow ripetibile:

- `data/vocab.json`
- `data/Flickr8k_text/train.csv`
- `data/Flickr8k_text/val.csv`
- `data/Flickr8k_text/test_captions.json`

Dimensioni finali osservate:

- 30000 righe di training
- 5000 righe di validation
- 1000 immagini di test
- 5 caption di riferimento per immagine

3.2 Pulizia del testo

Le caption sono state preprocessate applicando:

- conversione in minuscolo
- rimozione della punteggiatura
- rimozione dei numeri
- rimozione delle parole costituite da una sola lettera
- normalizzazione degli spazi

Il vocabolario finale contiene 2985 token, inclusi i token speciali `<pad>`, `<bos>`, `<eos>` e `<unk>`.

4 Architettura del modello

Il sistema implementato segue una struttura encoder-decoder.

4.1 Encoder

L'encoder utilizza InceptionV3 pre-addestrata su ImageNet. Il layer finale di classificazione è stato rimosso e le feature estratte sono state proiettate nello spazio di embedding utilizzato dal decoder.

4.2 Decoder

Il decoder è una LSTM a singolo layer. Durante il training riceve in input la rappresentazione dell'immagine e la sequenza di token della caption. Un layer lineare finale mappa gli hidden state del decoder nello spazio del vocabolario per la predizione del token successivo.

4.3 Tecniche di training

Il codice supporta:

- scheduled sampling
- label smoothing
- gradient clipping
- checkpointing del modello
- resume da checkpoint
- valutazione BLEU-1/BLEU-2/BLEU-3/BLEU-4

5 Dettagli implementativi

La repository è organizzata in moduli distinti:

- `src/vocab_builder.py`: pulizia testo, costruzione vocabolario, esportazione split
- `src/prepare_data.py`: script rapido per la preparazione dei dati
- `src/dataset.py`: dataset e batching
- `src/model.py`: definizione della CNN-LSTM
- `src/train.py`: training loop e checkpoint
- `src/eval.py`: generazione caption e calcolo BLEU
- `src/visualize.py`: figure qualitative
- `src/ui_streamlit.py`: demo interattiva opzionale

Durante la revisione del progetto sono stati corretti diversi problemi strutturali, tra cui:

- parsing scorretto del formato Flickr8k
- allineamento della loss sul next-token prediction
- attivazione reale del fine-tuning dell'encoder
- generazione automatica degli artefatti mancanti

6 Setup sperimentale

Tutti gli esperimenti finali sono stati eseguiti su:

- ambiente Python: `captioning`
- PyTorch: `2.9.1+cpu`
- device: CPU

Configurazioni confrontate:

1. Baseline
2. No Scheduled Sampling
3. No Label Smoothing
4. Fine-tuning della CNN

Nella comparazione finale tutte le configurazioni sono state eseguite per 5 epoche.

7 Risultati quantitativi

Tabella 1: Confronto BLEU tra gli esperimenti finali.

Esperimento	BLEU-1	BLEU-2	BLEU-3	BLEU-4
Baseline	0.2553	0.1556	0.0928	0.0472
No Scheduled Sampling	0.2232	0.1242	0.0717	0.0396
No Label Smoothing	0.2404	0.1435	0.0809	0.0394
Fine-tuning	0.3301	0.2022	0.1189	0.0649

Tabella 2: Riassunto del training.

Esperimento	Best Val Loss	Final Train Loss	Final Val Loss
Baseline	4.1927	4.8016	4.2332
No Scheduled Sampling	4.0106	3.5373	4.0234
No Label Smoothing	3.5029	4.0860	3.5738
Fine-tuning	3.6614	4.7512	4.2861

8 Discussione dei risultati

La baseline fornisce il punto di riferimento del progetto. Rimuovendo lo scheduled sampling si osserva un peggioramento di tutte le metriche BLEU, anche se la training loss risulta inferiore. Questo suggerisce che lo scheduled sampling migliori la generalizzazione del decoder durante la generazione autoregressiva.

Anche la rimozione del label smoothing produce un peggioramento delle metriche rispetto alla baseline, indicando che tale tecnica contribuisce positivamente alla qualità delle caption generate.

La configurazione con fine-tuning della CNN ha ottenuto i migliori risultati complessivi, migliorando il BLEU-4 da 0.0472 a 0.0649. Nel contesto di questo studio, il fine-tuning è quindi la scelta più efficace.

9 Analisi qualitativa




Figura 1: Esempio qualitativo della baseline. La caption predetta è parzialmente coerente ma rimane generica e incompleta rispetto alla descrizione reale.

A light-colored dog, possibly a Weimaraner, is captured in a full running stride on a green lawn. The dog is facing left, with its head turned slightly towards the camera, showing its teeth. It has a dark collar around its neck. The background is a lush green garden with various plants and flowers.

Predicted: hikes bread bread than war war so leading leading leading leading leading leading
 leading leading leading leading leading leading leading leading
 Ground Truth: four skiers walking up snow covered hill



10 Limiti del progetto

- 7

- L'architettura studiata è classica e non include confronti con modelli Transformer.

11 Conclusioni

Il progetto ha realizzato una pipeline completa di image captioning con CNN-LSTM su Flickr8k, dalla preparazione dei dati fino alla valutazione quantitativa e qualitativa. I risultati sperimentali mostrano che scheduled sampling e label smoothing migliorano le prestazioni rispetto alle rispettive ablation, mentre il fine-tuning dell'encoder produce il miglior risultato finale. La repository contiene ora codice, log, checkpoint, figure e file di risultati sufficienti per una consegna accademica completa e riproducibile.

Artefatti disponibili

- `results/metrics_summary.csv`
- `results/experiment_summary.csv`
- `results/*_predictions.json`
- `logs/*`
- `figures/*`
- `LAB_LOG.md`